## DS4001-25SP-HW2: 强化学习

TA: 戴维

2025 年 4 月 14 日

作业说明
------

本次作业包括书面部分(问题回答)和编程部分(代码填空)。

书面部分需使用 LaTeX 完成,模板文件为 report\_template.tex。注意: 为方便助教批改,你还需要将编程部分完成后的代码复制到模板中的对应位置。书面作业完成后,请导出为 report.pdf 文件。

编程部分的完整代码位于 Project 文件夹中。你仅需在 submission.py 中指定位置完成代码, 具体如下:

# BEGIN\_YOUR\_CODE

2

3 # END\_YOUR\_CODE

不要对除 submission.py 以外的文件进行更改。在完成所有代码编写后,你可以运行 python learner.py 学习到 Q 值表, 之后运行 python evaluator.py 进行评估。

完成所有内容后,请将 submission.py 与 report.pdf 打包成名为"学号 \_ 姓名 \_HW2.zip"的压缩文件,并上传至 BB 系统。助教将根据你提交的文件进行评分。

#### 注意事项:

- 本次作业必须独立完成,任何形式的抄袭都不允许。如发现有互相抄袭的情况,抄袭者将平分获得的分数。
- 作业的截止时间为 2024 年 5 月 8 日 23:59:59。 迟交 1/2/4/7 天分别会扣除 5/15/40/100 分。
- 如果在做作业过程中遇到问题,可以在 Github Issue 中提问或者线下在答疑课提问,也欢迎同学们相互解答问题。

#### 作业正文 \_\_\_\_\_

#### 1 问题 1: 马尔可夫决策过程 [9%]

考虑以下一个 MDP:

- 状态空间  $S = \{-2, -1, 0, 1, 2\};$
- 动作空间  $A = \{a_1, a_2\};$
- 初始状态  $s_0 = 0$ ,某一时刻 t 的状态  $s_t \in \{-2, 2\}$  时,该过程结束;
- 在时刻 t,有如下的定义  $P_{s',s,a} = \text{Prob}[s_{t+1} = s' | s_t = s, a_t = a]$ 。假设在环境噪声的影响下,有转移概率:

$$\begin{cases}
P_{i+1,i,a_1} = 0.2, P_{i,i,a_1} = 0.1, P_{i-1,i,a_1} = 0.7 \\
P_{i+1,i,a_2} = 0.3, P_{i,i,a_2} = 0.2, P_{i-1,i,a_2} = 0.5
\end{cases}$$
(1)

• 奖励函数

$$\mathcal{R}(s, a, s') = R(s_{t+1} = s' | s_t = s, a_t = a)$$

$$= \begin{cases} 20, & s' = 2\\ 10, & s' = -2\\ -1, & otherwise \end{cases}$$

- 衰减因子  $\gamma = 1$ 。
- (a) [6 分] 我们使用 Value Iteration 来评估改 MDP 的状态价值函数 V(s)。对于迭代轮次  $i \in \{0,1,2\}$ ,对应的状态价值函数为  $V^{(i)}(s)$ 。假设  $V^{(0)} \equiv 0$ ,请你求出所有所有的  $V^{(i)}(s)$ , $i \in \{0,1,2\}$  的值。
- (b) [3 分] 请根据你计算得到的  $V^{(2)}(s)$  值,给出当前迭代轮次(i=2)时的最优策略  $\mu(s)$ 。(你需要列出 3 个  $(s,\mu(s))$  数值对,两个吸收态不需要考虑)

## 2 问题 2: Q-Learning[12%]

(a) [3 分] 对于一个马尔可夫决策过程,我们定义一条轨迹(trajectory) $\tau = (s_t, a_t, r_t, s_{t+1}, a_{t+1}, r_{t+1}, \dots)$ 的回报为 $G_t$ 。其表达式为: $G_t = \sum_{k=t}^{+\infty} \gamma^{k-t} \mathcal{R}_k$ 。我们根据 $G_t$  可以定义状态价值函数 $V(s) = \mathbb{E}[G_t | s_t = s]$ ,以及动作价值函数 $Q(s, a) = \mathbb{E}[G_t | s_t = s, a_t = a]$ 。

基于上面的定义,请推导出 Q(s,a) 的表达形式,用状态价值函数 V(s') 表示。

- (b) [6 分] 将估计值的初始值设置为 0。对于定义在状态空间 S = 0,1 和动作空间  $A = a_1, a_2$  上的某一轨迹(trajectory) $\tau = \{(s_i, a_i, r_i)\}_4 = \{(0, a_1, 2), (1, a_1, 3), (0, a_2, -1), (1, a_2, 0)\}$ ,请手动写出估计值 q(s, a) 在时间  $1 \le t \le 4$  的更新过程(Monte Carlo Q-Learning)。
- (c) [3 分] 请简单解释 Q-Learning 算法为什么能够收敛。 (参考材料 https://zhuanlan.zhihu.com/p/365814943, 理解并复述文中证明的大致思路, 不需要复现其中的数学细节)

## 3 问题 3: Gobang Programming[53%]

你现在应当初步理解了强化学习的原理。现在,我们可以考虑更加现实的一个游戏——五子棋的简化版,"三子棋"。为方便起见,我们在这里将"三子棋"的规则统一为:

- 1. 棋盘大小: n=3;
- 2. 先手规则: 黑棋先下;
- 3. 终局判定:一旦某一方在**行、列、正反对角线任一方向**上达成连续的三个棋子,则这一方赢。否则, 若直到棋盘被填满仍未分出胜负,则双方平局。

在本题中,假定我们要训练的智能体是黑棋棋手,而白棋是一个只会随机落子的小白(因此可以把白棋落子视为环境噪声);那么我们也可以将其表述为一个规范的 MDP:

- 状态空间 S= 黑棋落子前所有棋盘可能的状态 s (某一位置  $s_{ij}=0$  表示无子,1 表示落黑子,2 表示落白子)
- 动作空间  $A = \{(x,y) \mid s_{xy} = 0\};$
- 初始状态  $s_0 = 0_{n \times n}$ ,终局判定达成时,游戏结束。
- 奖励函数  $R(s,a,s') = [L_b^2(s') L_w^2(s')] [L_b^2(s) L_w^2(s)]$ , 其中  $L_b(s)$  是状态 s 下黑棋的最长连续长度,  $L_w(s)$  是状态 s 下白棋的最长连线长度。
- 衰减因子  $\gamma = 0.5$ 。
- (a) [33 分] 按照 submission.py 中的要求,完成代码填空。按照代码正确性和能否完整运行给分。在本实验中,你需要实现 Q-Learning 算法,训练智能体进行三子棋的游戏。为了减少你的工作量,助教已经实现了三子棋的框架、Q-Learning 的基本代码以及一些辅助代码。你只需要额外补全以下几个函数即可。同时这里再做一些简单的提示:
  - get\_next\_state [5分],根据当前状态 self.board 和动作 action,返回下一个状态 next\_board。 你无须在这一部分对 self.board 进行修改;
  - sample\_noise [3 分],根据当前的状态和动作空间,随机生成一个白棋的落子位置;
  - get\_connection\_and\_reward [5 分],根据当前状态 self.board 和动作 action,返回下一个状态的奖励 reward,你可以使用 get\_next\_state 以及 self.count\_max\_connections 辅助实现 get\_connection\_and\_reward;

- sample\_action\_and\_noise [8 分],根据当前状态 self.board,依据 epsilon-greedy 策略输出 一个动作 action,同时返回一个白棋的落子位置。助教已经完成了调用 sample\_noise 函数生成白棋的落子位置的返回逻辑,你需要补充实现根据 epsilon-greedy 策略返回 action 的部分。若状态-动作对 (s,a) 在 self.Q 中未被记录,则应返回一个随机动作。动作确定后,需从动作空间中移除该动作;
- q\_learning\_update [12 分],你需要按照 Q-Learning 的更新公式来更新 self.Q。同时约定以下几个规则: 1. 在数学上默认所有 self.Q[s][a] 的初始值为 0。另外,状态 s 对应的动作空间为空(即棋盘已满或者游戏已经结束的情况)导致无法在空集上取 max 时,直接以 0 代替即可; 2. self.Q 被初始化为一个空字典,在后续中记录的 (s,a) Pair 也是有限的(如某一时刻,self.Q 的值可能是  $\{s_1: \{a_1:0.5,a_2:1.0\}, s_2: \{a_1:0.3\}, s_3: \{\}\}$  的形式,而  $s_4$  尚未被记录)。但是这样已经足以让我们实现正确的 Q-Learning 更新,请你想一想解决办法。
- (b) [10 分] 请你运行 learner.py 进行 Q Learning, 之后运行 evaluator.py 进行测试。你需要截取训练以及评估最后的截图,按照复现结果是否合理给分。(建议将评估轮次设置的稍大一些,这样会更准确)
- (c) [10 分] 将 learner.py 和 evaluator.py 中的参数更改为 n=4 (其他任何参数和代码均不做改变), 然后在 4\*4 的棋盘上尝试执行 QLearning 算法,并给出 evaluator.py 的运行结果。回答该结果是 否符合你的预期,并给出解释。

## 4 问题 4: Deeper Understanding[16%]

本节我们将从 Bellman 算子和重要性采样 (Importance Sampling) 进一步加深对强化学习的理解。

#### 4.1 Bellman 算子与压缩映射

强化学习的评估和优化本质上与 Bellman 算子密切相关。

1. 评估: 随机策略  $\pi(s,a) \in [0,1]$  的价值估计可以用算子  $T_{\pi}$  表示:

$$(\mathcal{T}_{\pi}v)(s) = \mathbb{E}_{a \in A} \left\{ r_{sa} + \gamma \cdot \sum_{s' \in S} p_{sas'} \cdot v(s') \right\} = \sum_{a \in A} \pi(s, a) \left[ r_{sa} + \gamma \cdot \sum_{s' \in S} p_{sas'} \cdot v(s') \right]$$

2. 优化:例如 Value Iteration,实质上就是通过迭代求解最优策略,这个过程同样可以用算子  $\mathcal T$  表示:

$$(\mathcal{T}v)(s) = \max_{a \in A} \left\{ r_{sa} + \gamma \cdot \sum_{s' \in S} p_{sas'} \cdot v(s') \right\}$$

3. 有如上定义之后,  $v_{\pi}, v^* \in \mathbb{R}^{|S|}$  实际上是对应 Bellman 方程的解:

$$\mathcal{T}v^* = v^*, \quad \mathcal{T}_{\pi}v_{\pi} = v_{\pi}$$

其中

$$v_{\pi}(s) = \mathbb{E}[G_t \mid S_t = s, A \sim \pi], \quad v^*(s) = \max_{\pi} \{v_{\pi}(s)\}$$

请根据上面的内容回答下面的问题:

- (a) [5 分] 考虑具有有限状态和动作空间的 MDP,以及折扣因子  $\gamma$ 。证明  $\mathcal{T}$  是压缩映射,即对于  $v_1, v_2 \in \mathbb{R}^{|S|}$ ,我们恒有  $\|\mathcal{T}v_1 \mathcal{T}v_2\| \leq \gamma \|v_1 v_2\|_{\infty}$ 。(这表明 Bellman 算子是最大范数中的 " $\gamma$ -收缩")
- (b) [5 分] 如果 Tv = v,则我们称 v 是 T 的不动点。利用 Bellman 算子是最大范数中的  $\gamma$  收缩这一事实,证明 T 最多有一个不动点,即 Bellman 方程最多有一个解。你可以假设 T 至少有一个不动点。提示:在部分 (a) 中证明的结果意味着值迭代几何收敛到最优值函数 v\*。也就是说,经过 k 次迭代后,v 与 v\* 之间的距离最多为  $\gamma^k$ 。

#### 4.2 重要性采样

在异策略(Off-Policy)强化学习中,重要性采样(Importance Sampling)是一种关键方法,用于通过采样策略  $\pi_a$  生成的样本估计目标策略  $\pi_b$  的期望回报。基于重要性采样,OpenAI 提出了近端策略优化算法(proximal policy optimization,PPO)。在这一节,我们将完成重要性采样的推导。

- (a) [2 分] 记 p,q 为关于 x 的两个分布,请证明  $\mathbb{E}_{x\sim p}[f(x)] = \mathbb{E}_{x\sim q}[f(x)\frac{p(x)}{q(x)}]$ 。 (在强化学习的策略优化中,我们可以将 q 看作采样的策略,p 看作需要优化的目标策略。上式可以理解为:我们通过 q 获得的样本获得了对需要优化的目标函数的无偏估计)
- (b)  $[4\ \mathcal{H}]$  证明  $\mathrm{Var}_{x\sim p}[f(x)] \mathrm{Var}_{x\sim q}[f(x)\frac{p(x)}{q(x)}] = \mathbb{E}_{x\sim p}[f(x)^2] \mathbb{E}_{x\sim p}[f(x)^2\frac{p(x)}{q(x)}]$ 。 提示:  $\mathrm{Var}[X] = \mathbb{E}[X^2] (\mathbb{E}[X])^2$ ,请注意在期望符号右下角标明 x 来自何种分布。 (该结果表明虽然  $f(x)\frac{p(x)}{q(x)}, x\sim q$  和  $f(x), x\sim p$  的期望相同,但是他们的方差存在差距。二者的方差相差较大将导致模型训练的不稳定。因此在实践中,我们要求分布 p 与 q 不能相差过大,PPO 中引入了 KL-散度惩罚项来控制这一点,后续为了优化 KL-散度的计算,又出现了基于 clip 操作的近端策略优化裁剪算法)

作业反馈
------

# 体验反馈 [10%]

你可以写下任何反馈,包括但不限于以下几个方面:课堂、作业、助教工作等等。

- (a) [必做] 你在本次作业花费的时间大概是?
- (b) [选做] 你可以随心吐槽课程不足的方面,或者给出合理的建议。